



Projet de fin d'études

Planneur pour la mobilité intelligente de véhicules

CANNOUX	Michel
FIZAINE	Mickaël
HANG	Ian
MOKEDDEM	Wissal

Vendredi 04 Avril 2025

Contents

1	Introduction	1
1.1	Introduction	1
1.1.1	Contexte et importance du sujet	1
1.1.2	Problématique et objectifs de recherche	1
1.1.3	Grandes questions abordées dans l'état de l'art	2
1.1.4	Organisation de l'état de l'art	2
2	État de l'art	3
2.1	Présentation générale du domaine	3
2.1.1	Introduction et historique du domaine	3
2.1.2	Concepts et approches clés	3
2.1.3	Applications et recherches existantes	4
2.1.4	Synthèse et perspectives	5
2.2	Travaux existants et état actuel de la recherche	5
2.2.1	Modélisation énergétique du véhicule	5
2.2.2	Apprentissage automatique et intelligence artificielle pour la planification	6
2.2.3	Optimisation du routage et de la mobilité intelligente	7
2.2.4	Prise en compte des facteurs environnementaux et externes	8
2.2.5	Interaction Véhicule-Infrastructure-Usagers (V2X)	9
2.2.6	Intégration des processus embarqués et débarqués	10
2.3	Lacunes des méthodes existantes	11
2.3.1	Modélisation énergétique du véhicule	11
2.3.2	Apprentissage automatique et intelligence artificielle	11
2.3.3	Optimisation du routage des véhicules électriques	11
2.3.4	Prise en compte des facteurs environnementaux	11
2.3.5	Interaction Véhicule-Infrastructure-Usagers (V2X)	11
2.3.6	Synchronisation des processus embarqués et débarqués	11
2.3.7	Défis techniques et scientifiques	11
2.4	Synthèse des conclusions de l'état de l'art	12
2.4.1	Justification de l'approche proposée	12
2.4.2	Hypothèses et objectifs de la recherche	13
2.5	Conclusion	13
3	Implémentation et résultats	14
3.1	Implémentation d'un prototype de navigation urbaine	14
3.1.1	Objectifs	14
3.1.2	Méthodologie	14
3.1.3	Résultats	14
3.2	Implémentation d'un algorithme d'optimisation	16
3.2.1	Principe de l'algorithme	16
3.2.2	Méthodologie	18
3.2.3	Implémentation	18
3.2.4	Résultats (Exemple sur le véhicule 1)	18
3.3	Implémentation d'un algorithme de négociation	19
3.3.1	Principe et méthode	19

3.3.2	Quelques exemples de négociation	20
3.4	Résultat final	21
4	Conclusion	22
4.1	Synthèse du projet	22
4.2	Limites du prototype développé	22
4.3	Perspectives d'amélioration	22

Abstract

La mobilité intelligente des véhicules électriques est un enjeu central pour l'optimisation des trajets et de l'approvisionnement énergétique en milieu urbain. Ce projet vise à proposer des mécanismes avancés permettant de guider dynamiquement les décisions des véhicules en matière de parcours et de recharge, tout en tenant compte des contraintes énergétiques, économiques et environnementales. Nous développons un modèle d'optimisation multi-objectifs intégrant plusieurs stratégies afin de minimiser le temps de trajet, le coût de l'énergie, la consommation électrique et de fluidifier le trafic. À terme, cette approche pourrait inclure la gestion des infrastructures cloud et l'interconnexion en temps réel entre véhicules et bornes de recharge.

Chapter 1

Introduction

1.1 Introduction

1.1.1 Contexte et importance du sujet

La transition vers les **véhicules électriques (VE)** constitue une avancée majeure dans la réduction des émissions de gaz à effet de serre et la lutte contre le changement climatique. Cependant, cette transition pose plusieurs défis majeurs en matière de **gestion intelligente des trajets et de l'énergie**, notamment :

- La **congestion des infrastructures de recharge**, qui entraîne des temps d'attente élevés aux bornes et une répartition inégale de l'accès à l'énergie.
- La **planification inefficace des trajets**, qui peut accroître la consommation énergétique et générer des embouteillages, nuisant ainsi à la fluidité du trafic.
- L'**impact économique** pour l'usager, où le coût de l'électricité varie en fonction des horaires et des politiques de tarification dynamique.
- La **nécessité d'une coordination intelligente entre véhicules et infrastructures (V2X)** pour éviter des pics de consommation d'énergie et assurer une meilleure répartition des ressources.

Les solutions traditionnelles, basées sur des itinéraires pré-calculés ou des recharges opportunistes, ne permettent pas de répondre efficacement à ces défis. Il est donc essentiel de concevoir des **modèles d'optimisation avancés** capables d'intégrer des données en temps réel et d'adapter dynamiquement les décisions des véhicules en fonction de l'état du réseau, des besoins des usagers et des conditions environnementales.

1.1.2 Problématique et objectifs de recherche

L'optimisation de la mobilité intelligente des véhicules électriques repose sur la prise de décisions stratégiques concernant les itinéraires, les recharges et l'interaction avec les infrastructures. Toutefois, ces décisions doivent être adaptées aux **préférences des utilisateurs**, notamment en ce qui concerne le **coût de l'énergie** et la **stratégie de mobilité** adoptée.

L'objectif principal de cette recherche est de développer un **modèle d'optimisation multi-objectifs** permettant d'améliorer la gestion des trajets et des recharges tout en s'adaptant aux contraintes des usagers. Ce modèle vise à guider **dynamiquement** les décisions en matière :

- de **choix d'itinéraires** (minimisation du temps de trajet et réduction de la congestion),
- de **gestion énergétique** (optimisation de la recharge en tenant compte du coût, de la disponibilité des bornes et de la tarification dynamique),
- de **fluidification du trafic** (anticipation des pics de demande et ajustement des flux de véhicules),
- de **gestion des coûts en fonction des stratégies utilisateur** (équilibre entre coût de l'énergie, rapidité de recharge et autonomie du véhicule),

- et, à terme, de **communication en temps réel entre véhicules et infrastructures** (V2X) pour une meilleure coordination.

Un des aspects clés de cette optimisation repose sur la **flexibilité du modèle face aux différentes stratégies des usagers**. Par exemple :

- Un utilisateur privilégiant un **coût minimal** pourra se voir proposer des stations de recharge moins onéreuses, quitte à rallonger légèrement son itinéraire.
- Un utilisateur recherchant **une recharge rapide** pourra être dirigé vers des stations rapides, mais potentiellement plus coûteuses.
- Une optimisation combinée pourra chercher un **compromis entre coût, temps et autonomie**, prenant en compte des paramètres tels que la tarification horaire et la consommation énergétique.

Ainsi, l'approche proposée vise à modéliser **une prise de décision multi-critères** où chaque véhicule ajuste dynamiquement ses choix en fonction de son profil d'usage, des contraintes environnementales et des stratégies d'optimisation définies par l'utilisateur.

1.1.3 Grandes questions abordées dans l'état de l'art

Afin de mieux comprendre et résoudre ces défis, cet état de l'art explorera plusieurs grandes questions :

1. **Quels sont les principaux modèles d'optimisation multi-objectifs utilisés dans la planification des trajets et de la recharge des VE ?** Nous analyserons les approches existantes, qu'elles soient basées sur des algorithmes heuristiques, des méthodes exactes ou des modèles d'apprentissage automatique.
2. **Comment intégrer des paramètres environnementaux et contextuels (météo, trafic, occupation des bornes) dans les modèles de décision ?** L'état de l'art présentera différentes stratégies permettant d'intégrer ces facteurs et d'adapter les décisions en temps réel.
3. **Quels sont les défis liés à la communication entre véhicules et infrastructures (V2X) et comment ces interactions peuvent-elles améliorer l'optimisation des trajets ?** Nous étudierons les différentes solutions proposées pour l'échange d'informations en temps réel et leur impact sur l'efficacité globale du système.
4. **Quelles sont les limites des approches actuelles et quels sont les axes d'amélioration envisageables ?** Une analyse critique des modèles existants mettra en évidence les lacunes et les pistes d'amélioration potentielles.

1.1.4 Organisation de l'état de l'art

Ce document est structuré comme suit : Dans la **section suivante**, nous présenterons un **état de l'art détaillé** des méthodes utilisées pour l'optimisation des trajets et de la recharge des VE. Ensuite, nous discuterons des **approches de modélisation et d'apprentissage automatique** qui permettent d'intégrer les données contextuelles en temps réel. Enfin, nous analyserons les **perspectives futures et les défis techniques**, notamment ceux liés à la communication entre véhicules et infrastructures.

Chapter 2

État de l'art

2.1 Présentation générale du domaine

2.1.1 Introduction et historique du domaine

L'optimisation de la mobilité intelligente des véhicules électriques (VE) s'inscrit dans un cadre plus large d'études sur les systèmes de transport intelligents (ITS - *Intelligent Transportation Systems*). Ces systèmes combinent l'intelligence artificielle, l'optimisation mathématique et l'Internet des Objets (IoT) pour améliorer la gestion des infrastructures de transport et des flux de véhicules.

L'essor des ITS remonte aux années 1990, lorsque les premières applications d'optimisation des flux routiers ont vu le jour avec des méthodes de régulation du trafic urbain et des systèmes GPS intégrés. L'arrivée des véhicules électriques et des préoccupations environnementales dans les années 2000 a profondément transformé le champ de la recherche en transport, nécessitant de nouveaux modèles prenant en compte :

- L'optimisation énergétique spécifique aux VE (consommation, recharge, autonomie).
- L'intégration de données en temps réel pour ajuster les trajets et la recharge.
- La planification adaptative tenant compte de l'évolution du réseau routier et de la congestion des infrastructures.

Aujourd'hui, les travaux de recherche se concentrent sur des solutions basées sur l'intelligence artificielle et l'optimisation multi-objectifs afin de garantir une mobilité fluide et efficace des VE.

2.1.2 Concepts et approches clés

L'optimisation de la mobilité intelligente des VE repose sur plusieurs concepts fondamentaux issus des domaines suivants :

Optimisation combinatoire et recherche opérationnelle

Les premiers modèles d'optimisation des itinéraires reposaient sur la théorie des graphes et les algorithmes de recherche de chemin optimal tels que :

- **L'algorithme de Dijkstra** : utilisé pour trouver le chemin le plus court dans un graphe pondéré.
- **L'algorithme A*** : une amélioration de Dijkstra intégrant une fonction heuristique pour accélérer la recherche.
- **Les algorithmes Bellman-Ford et Floyd-Warshall** : exploitant des poids négatifs pour intégrer des contraintes spécifiques.

Cependant, ces approches ne prennent pas en compte les contraintes énergétiques des VE, ce qui a conduit à des modifications telles que l'introduction du **Problème du Plus Court Chemin à Préfixe Borné (PBSP)** étudié par Artmeier et al. [1].

Intelligence artificielle et apprentissage automatique

Avec l'augmentation des données disponibles sur la mobilité, les algorithmes d'**apprentissage automatique** ont été intégrés aux modèles de décision :

- **Les réseaux neuronaux profonds (DNNs)** pour la prédiction de la consommation énergétique en fonction du relief et des conditions de circulation.
- **Les modèles d'apprentissage supervisé** pour anticiper les besoins en recharge des utilisateurs.
- **Les approches par renforcement (RL - Reinforcement Learning)** pour l'apprentissage dynamique des itinéraires les plus efficaces.

Des travaux présentés à l'**IJCAI** [8] ont démontré que ces méthodes permettent d'adapter les décisions en temps réel et d'améliorer la performance énergétique globale.

Planification multi-agents et optimisation distribuée

Un autre axe de recherche majeur est l'utilisation des **systèmes multi-agents**, notamment pour la gestion des flottes de VE et la coordination des infrastructures :

- Les **algorithmes coopératifs** permettent aux véhicules de partager des informations sur la disponibilité des bornes et d'optimiser leur itinéraire en fonction des décisions des autres usagers.
- Les **modèles décentralisés** permettent une prise de décision locale en fonction des conditions observées.
- Les approches **V2X (Vehicle-to-Everything)** facilitent l'échange d'informations entre véhicules et infrastructures.

Des recherches issues de la conférence **AAMAS** [6] ont prouvé que ces approches permettent de réduire significativement la congestion aux bornes de recharge et d'améliorer l'efficacité énergétique des flottes de VE.

2.1.3 Applications et recherches existantes

Les modèles d'optimisation de la mobilité intelligente des VE sont aujourd'hui appliqués à plusieurs niveaux :

Navigation et optimisation des trajets

Les systèmes de navigation comme **Google Maps** et **Waze** utilisent des algorithmes d'optimisation des itinéraires, mais intègrent peu les spécificités des VE. Des recherches académiques tentent d'intégrer :

- L'optimisation basée sur la consommation énergétique [1].
- L'optimisation en temps réel selon la disponibilité des bornes [8].
- Les systèmes hybrides combinant recherche de plus court chemin et prévisions IA [7].

Gestion des infrastructures de recharge

L'optimisation ne se limite pas aux trajets, mais concerne également l'occupation et la distribution des ressources énergétiques :

- **Gestion dynamique des bornes de recharge** : anticipation des pics de demande.
- **Tarification intelligente** : modulation des prix en fonction de l'affluence.
- **Coordination des infrastructures via le cloud** [6].

Optimisation des flottes et logistique

Les entreprises de logistique adoptent des modèles d'optimisation pour réduire leur empreinte carbone :

- **Flottes électriques pour la livraison urbaine** : intégration des stratégies multi-agents.
- **Systèmes de gestion en temps réel** : adaptation aux conditions routières et météorologiques.

Des solutions comme celles développées dans les conférences **AAMAS** et **IJCAI** permettent d'optimiser les parcours en fonction des infrastructures disponibles.

2.1.4 Synthèse et perspectives

L'évolution de la recherche en mobilité intelligente des VE montre une convergence entre les méthodes classiques d'optimisation et les avancées récentes en intelligence artificielle. Plusieurs tendances se dégagent :

- L'intégration croissante de l'IA pour des prévisions précises et une prise de décision automatisée.
- L'importance des approches multi-agents pour améliorer la gestion collective des ressources.
- Le besoin d'interopérabilité entre véhicules, infrastructures et gestion des données via le cloud.

Dans les prochaines sections, nous explorerons en détail les **travaux existants** dans ces domaines, leurs avantages et leurs limites, afin de justifier la pertinence de notre approche d'optimisation multi-objectifs.

2.2 Travaux existants et état actuel de la recherche

2.2.1 Modélisation énergétique du véhicule

La modélisation énergétique des véhicules électriques (VE) est un domaine de recherche essentiel pour optimiser leur autonomie, leur consommation énergétique et les stratégies de recharge. Cette section présente un état de l'art des travaux récents sur la consommation énergétique des VE, les facteurs influençant leur autonomie et les approches mathématiques pour une modélisation personnalisée.

Consommation énergétique des véhicules électriques

La consommation énergétique des VE dépend de plusieurs facteurs, notamment la topographie du trajet, les conditions météorologiques, le style de conduite et la charge embarquée. Les travaux de [12] ont mis en évidence l'importance de la planification des tournées pour minimiser la consommation d'énergie et optimiser l'utilisation des stations de recharge. L'intégration de modèles mathématiques et heuristiques permet une amélioration significative de l'autonomie des VE.

Facteurs influençant l'autonomie des VE

L'autonomie des VE est fortement influencée par des paramètres externes. Par exemple, [9] ont développé un modèle multi-objectif combinant l'optimisation de la consommation à la prévision des temps de recharge selon les conditions réelles du trafic et de l'infrastructure. Ce modèle intègre des graphes routiers à grande échelle pour planifier des itinéraires optimaux.

Définitions Clés

Selon [12], la consommation énergétique d'un véhicule électrique est définie comme la quantité d'énergie utilisée par unité de distance parcourue, mesurée en kWh/km. [3] introduisent également le concept de tarification dynamique, qui désigne un système adaptatif où les prix de recharge varient en fonction de la demande et de l'offre sur le réseau.

Optimisation de l'énergie et stratégies de recharge

L'optimisation de la recharge est un enjeu central pour les VE. Différentes approches sont explorées, allant des heuristiques à la programmation mathématique avancée. Les travaux de [12] mettent en évidence l'intérêt des métaheuristiques pour optimiser les tournées avec prise en compte des stations de recharge. De même, [9] montrent que les modèles multi-objectifs sont plus efficaces pour minimiser le temps de trajet tout en optimisant l'utilisation des bornes.

Discussion et perspectives

Les approches actuelles offrent des solutions prometteuses mais rencontrent certaines limitations. Parmi les principaux défis identifiés :

- La scalabilité des modèles à grande échelle [9].
- La nécessité d'intégrer davantage de données réelles pour une prédiction plus précise [3].

- La réduction du temps de calcul tout en conservant des performances optimales [12].

La modélisation énergétique des véhicules électriques est un domaine en pleine évolution, où l'intégration de modèles avancés permet d'améliorer significativement les performances. Les travaux futurs devront se concentrer sur l'amélioration de la précision des modèles et leur adaptabilité aux conditions réelles.

2.2.2 Apprentissage automatique et intelligence artificielle pour la planification

L'utilisation de l'apprentissage automatique et de l'intelligence artificielle pour la planification des véhicules électriques (VE) permet d'optimiser la gestion des infrastructures de recharge et d'améliorer l'expérience utilisateur. Cette section explore les approches existantes pour la génération de profils d'usagers, la reconnaissance dynamique des intentions des conducteurs, la prédiction des besoins en recharge et l'optimisation des itinéraires.

Génération de profils d'usagers

La génération de profils d'usagers repose sur l'analyse des données de mobilité collectées à partir des habitudes de conduite et des historiques de déplacement. [16] ont montré que l'intégration de facteurs externes comme la météo, le trafic et les événements locaux améliore la précision des prédictions de recharge. Leur modèle utilise des forêts aléatoires, des machines à vecteurs de support (SVM), XGBoost et des réseaux neuronaux profonds pour affiner la segmentation des utilisateurs.

Reconnaissance dynamique des intentions des conducteurs

La reconnaissance des intentions des conducteurs repose sur l'analyse en temps réel des habitudes de conduite. Les méthodes d'apprentissage supervisé permettent d'identifier des schémas comportementaux et d'ajuster les recommandations en fonction des préférences individuelles. [16] démontrent que l'utilisation de modèles basés sur des données historiques peut améliorer l'efficacité des systèmes de recommandation, notamment pour la gestion des stations de recharge.

Prédiction des besoins en recharge et itinéraire optimal

Les modèles prédictifs de recharge s'appuient sur des algorithmes de machine learning pour estimer la consommation énergétique future des VE. [16] proposent une approche combinant l'analyse de séries temporelles et l'apprentissage profond pour prévoir la durée des sessions de recharge et ajuster dynamiquement les itinéraires en fonction des disponibilités des bornes de recharge.

Systèmes de recommandation en temps réel

L'optimisation de la recharge en temps réel passe par des systèmes de recommandation intelligents capables d'adapter les décisions en fonction de l'évolution du trafic et de la demande en énergie. [3] ont développé un modèle de tarification dynamique basé sur le cloud computing, qui ajuste les coûts de recharge en fonction de l'équilibre entre l'offre et la demande, favorisant ainsi une meilleure répartition des ressources.

Discussion et perspectives

Les approches actuelles montrent une nette amélioration dans la gestion des recharges et la planification des déplacements. Cependant, plusieurs défis restent à relever :

- L'intégration de données hétérogènes pour une meilleure personnalisation [16].
- La nécessité d'améliorer la réactivité des systèmes de recommandation [3].
- L'optimisation des algorithmes pour minimiser le temps de calcul et l'empreinte énergétique [16].

Conclusion

L'utilisation de l'apprentissage automatique pour la planification des véhicules électriques est un levier essentiel pour une mobilité plus efficace et durable. L'amélioration des algorithmes de prédiction et la gestion intelligente des infrastructures de recharge constituent des axes majeurs pour les recherches futures.

2.2.3 Optimisation du routage et de la mobilité intelligente

L'optimisation du routage des véhicules électriques (EVRP) est un problème clé pour améliorer l'efficacité énergétique et réduire l'empreinte carbone des transports. Cette section présente un état de l'art des travaux récents sur l'optimisation du routage des véhicules électriques, les méthodes utilisées, ainsi que les défis à relever.

Problème du routage des véhicules électriques (EVRP)

L'EVRP est une extension du problème classique de tournées de véhicules (VRP), dans lequel les véhicules électriques doivent s'arrêter à des stations de recharge en raison de leur autonomie limitée [11].

Formellement, le problème peut être modélisé comme suit :

$$\min \sum_{(i,j) \in A} c_{ij} x_{ij} \quad (2.1)$$

Sous les contraintes :

$$\sum_{j \in V} x_{ij} = 1, \quad \forall i \in \mathbb{N} \setminus \{0\} \quad (2.2)$$

$$\sum_{i \in V} x_{ij} = 1, \quad \forall j \in \mathbb{N} \setminus \{0\} \quad (2.3)$$

$$SOC_j = SOC_i - e_{ij} x_{ij} + r_j, \quad \forall (i,j) \in A \quad (2.4)$$

avec :

- x_{ij} : variable binaire indiquant si l'arc (i,j) est emprunté.
- c_{ij} : coût énergétique ou temporel de l'arc (i,j) .
- SOC_i : niveau de charge de la batterie en arrivant au nœud i .
- e_{ij} : consommation d'énergie entre les nœuds i et j .
- r_j : énergie récupérée en rechargeant au nœud j .

Méthodes d'optimisation

Plusieurs approches ont été développées pour résoudre l'EVRP :

- **Méthodes exactes** : formulation en programmation linéaire mixte (MILP) [15].
- **Métaheuristiques** : algorithmes tels que l'algorithme génétique (GA) et l'optimisation par essaim de particules (PSO) [14].
- **Optimisation multi-objectifs** : prise en compte simultanée des critères de coût et de temps [9].

Prise en compte des contraintes dynamiques

L'optimisation du routage des véhicules électriques doit intégrer des contraintes temps-réel comme l'état des routes et le trafic. [12] propose un modèle où la prise en compte des temps d'attente aux bornes de recharge est essentielle pour minimiser les délais de trajet [11].

Discussion et perspectives

Les approches existantes offrent des solutions prometteuses mais rencontrent certaines limitations :

- La complexité du problème croît avec la taille du réseau routier.
- L'optimisation multi-objectifs reste coûteuse en temps de calcul.
- La nécessité de modéliser des scénarios en temps réel pour une meilleure efficacité opérationnelle.

L'EVRP est un domaine de recherche en plein essor où les progrès de l'optimisation combinatoire et de l'intelligence artificielle ouvrent de nouvelles perspectives. Les travaux futurs devront s'orienter vers des solutions hybrides combinant méthodes exactes et heuristiques pour garantir à la fois rapidité et qualité des solutions.

2.2.4 Prise en compte des facteurs environnementaux et externes

L'impact des facteurs environnementaux et externes sur l'autonomie et la consommation énergétique des véhicules électriques (VE) est un domaine de recherche fondamental pour optimiser leur efficacité et leur adoption à grande échelle. Cette section examine les principales recherches sur l'influence des conditions météorologiques, de l'état des routes, du taux d'occupation des bornes de recharge et de l'impact du trafic sur la mobilité des VE.

Impact des données météorologiques sur la consommation d'énergie

Les conditions météorologiques influencent directement la consommation d'énergie des VE. Par exemple, une température ambiante basse réduit l'efficacité des batteries et accroît la consommation pour le chauffage [2]. De même, les vents contraires et les précipitations augmentent la résistance au roulement et à l'aérodynamisme, entraînant une surconsommation.

L'impact peut être modélisé par l'équation suivante, où E représente la consommation d'énergie du VE :

$$E = E_0 + \alpha T + \beta v_w + \gamma P \quad (2.5)$$

où :

- E_0 est la consommation de base du véhicule,
- T est la température extérieure ($^{\circ}\text{C}$),
- v_w est la vitesse du vent (m/s),
- P est le coefficient de précipitation (mm/h),
- α, β, γ sont des coefficients ajustés expérimentalement.

L'étude de [9] propose un modèle multi-objectif combinant optimisation énergétique et prévision météorologique pour adapter les stratégies de recharge.

État des routes, pentes et obstacles

L'état des infrastructures routières influence l'efficacité énergétique des VE. Des routes accidentées ou en mauvais état augmentent la résistance au roulement, et les dénivels modifient la consommation énergétique en fonction de la pente [11].

La consommation d'énergie peut être exprimée comme suit :

$$E = E_0 + \delta G + \epsilon S \quad (2.6)$$

où :

- G est l'inclinaison de la pente (en degrés),
- S est le coefficient de rugosité de la route,
- δ, ϵ sont des coefficients empiriques dépendant du véhicule.

Selon [15], les modèles d'optimisation du routage doivent inclure ces paramètres pour réduire la consommation d'énergie globale.

Taux d'occupation des bornes de recharge et prévision des attentes

La disponibilité des bornes de recharge est un facteur critique pour la gestion des VE. Les files d'attente aux stations augmentent le temps de trajet total et influencent les décisions des conducteurs en matière de recharge [11].

Le modèle de file d'attente dans une station de recharge peut être décrit par un processus de Poisson, où λ est le taux d'arrivée des véhicules et μ est le taux de service des bornes :

$$P_n = \frac{\frac{\lambda^n}{\mu^n}}{C} \sum_{k=0}^{C-1} \frac{\lambda^k}{\mu^k} \quad (2.7)$$

où P_n représente la probabilité d'avoir n véhicules en attente et C est la capacité totale des bornes. Les résultats de [11] montrent que l'intégration de prévisions basées sur les données historiques et en temps réel améliore la gestion des files d'attente.

Effets du trafic sur l'autonomie et les temps de trajet

Le trafic routier est un facteur externe influençant l'autonomie des VE. Un trafic dense entraîne des arrêts fréquents, augmentant la consommation énergétique due aux relances fréquentes et à l'utilisation du freinage régénératif [9]. L'optimisation des itinéraires en fonction des conditions de circulation en temps réel repose sur des algorithmes de recherche A* et des métahéuristiques comme l'algorithme génétique [15]. L'approche multi-objective développée par [9] utilise une combinaison de recherche A* et de contraction hiérarchique pour réduire les temps de calcul tout en optimisant les trajets.

Discussion et perspectives

Les études actuelles montrent que l'intégration de facteurs environnementaux et externes dans la modélisation énergétique des VE permet d'améliorer la précision des prédictions et d'optimiser la gestion des infrastructures. Cependant, certains défis demeurent :

- L'amélioration de la précision des modèles météorologiques pour anticiper les conditions affectant la consommation énergétique.
- L'optimisation dynamique du routage en fonction des conditions réelles de trafic et des infrastructures disponibles.
- L'intégration de capteurs intelligents et d'outils d'intelligence artificielle pour une adaptation en temps réel aux conditions externes.

L'intégration des facteurs environnementaux et externes dans la gestion des VE est essentielle pour une mobilité plus efficace et durable. Les recherches récentes montrent que des modèles multi-objectifs et des approches d'optimisation avancées peuvent considérablement améliorer la planification énergétique et la gestion des bornes de recharge.

2.2.5 Interaction Véhicule-Infrastructure-Usagers (V2X)

L'interaction entre les véhicules électriques, les infrastructures routières et les usagers est un aspect fondamental du développement des systèmes de mobilité intelligente. La communication V2X (Vehicle-to-Everything) inclut l'échange de données entre véhicules (V2V), entre véhicules et infrastructures (V2I), et avec des usagers ou des systèmes connectés plus larges (V2N). Cette section présente les différents aspects de ces interactions et leur impact sur l'efficacité collective des véhicules électriques.

Communication entre véhicules (V2V)

Les systèmes de communication entre véhicules permettent d'améliorer la fluidité du trafic et de réduire la consommation d'énergie en optimisant les décisions de conduite. [5] présentent une architecture SDN basée sur le fog computing qui permet une transmission rapide des informations de trafic et une synchronisation efficace entre les véhicules. L'intégration de ces systèmes peut aider à la coordination dynamique des mouvements et à la prédiction des situations de congestion.

Échange de données avec les infrastructures routières et bornes de recharge (V2I)

L'échange d'informations avec les infrastructures routières et les bornes de recharge est crucial pour l'optimisation de la gestion énergétique des VE. Selon [4], un modèle de tarification dynamique basé sur le cloud peut être utilisé pour planifier efficacement la recharge des VE en fonction de la demande et de la disponibilité des bornes.

Systèmes collaboratifs et gestion globale du réseau de mobilité

La gestion collaborative des ressources énergétiques et des flux de véhicules permet d'optimiser les performances globales des réseaux de transport. [17] introduisent une approche hiérarchique pour la gestion des demandes de recharge, en exploitant les capacités des architectures fog computing pour assurer une prise de décision en temps réel et une réduction de la latence dans la communication des données.

Impact des interactions sur l'efficacité collective des véhicules électriques

L'intégration des systèmes de communication V2X améliore l'efficacité globale des véhicules électriques en réduisant les temps d'attente aux bornes de recharge et en optimisant la gestion du trafic. L'utilisation de réseaux d'information décentralisés permet d'adapter dynamiquement les stratégies de circulation et de recharge pour minimiser la consommation d'énergie et les délais [17].

L'interaction V2X constitue une avancée majeure dans le domaine des véhicules électriques, en facilitant l'optimisation des décisions de mobilité et de recharge. Les recherches futures devront se concentrer sur l'amélioration des protocoles de communication et l'intégration des technologies de cloud et fog computing pour une meilleure résilience et adaptabilité.

2.2.6 Intégration des processus embarqués et débarqués

L'intégration des processus embarqués et débarqués dans les véhicules électriques est un enjeu majeur pour l'optimisation de la mobilité intelligente. Cette section examine les approches existantes permettant de coordonner les décisions locales des véhicules avec les décisions globales du système de transport, en minimisant les coûts énergétiques et les temps d'attente.

Coordination entre les décisions locales et globales

La coordination entre les décisions locales (prises par le véhicule en fonction des données en temps réel) et les décisions globales (prenant en compte l'ensemble du réseau de transport) repose sur l'utilisation d'algorithmes avancés de gestion du trafic et d'optimisation. [13] a proposé une approche hybride combinant des stratégies de contrôle centralisé et distribué pour améliorer l'efficacité des décisions de mobilité. Ces modèles intègrent des techniques de planification dynamique basées sur l'apprentissage automatique pour ajuster en temps réel les trajets et les stratégies de recharge.

Impact des comportements individuels sur l'optimisation collective

L'optimisation collective de la mobilité repose sur une harmonisation entre les comportements individuels des conducteurs et les objectifs globaux d'efficacité énergétique. [2] souligne l'importance de la modélisation prédictive des flux de véhicules pour anticiper les congestions et réorienter les utilisateurs vers des itinéraires alternatifs. De plus, l'utilisation des architectures de cloud computing, comme discuté par [3], permet une gestion plus efficace des demandes énergétiques et des décisions de recharge en réseau.

Minimisation des coûts énergétiques et des temps d'attente

L'un des principaux défis de l'intégration des processus embarqués et débarqués est la minimisation des coûts énergétiques tout en garantissant un temps de trajet optimal. [3] propose un modèle de tarification dynamique basé sur le cloud qui ajuste les sessions de recharge en fonction de la disponibilité des infrastructures et de la demande énergétique. Ce modèle permet de réduire les pics de consommation et d'optimiser l'utilisation des bornes de recharge.

Synchronisation entre l'apprentissage local et les décisions centralisées

Les modèles d'apprentissage distribués, tels que ceux décrits par [17], permettent une meilleure synchronisation entre l'apprentissage local effectué par chaque véhicule et les décisions centralisées du réseau. L'architecture de fog computing présentée dans cet article renforce la flexibilité du système en réduisant la latence des décisions et en optimisant les ressources réseau pour une communication efficace entre les véhicules et les infrastructures.

Discussion et perspectives

Bien que les approches actuelles offrent des solutions prometteuses, plusieurs défis persistent :

- L'amélioration de la scalabilité des modèles distribués [13].
- L'intégration de nouvelles sources de données pour affiner la prise de décision [2].
- La réduction du coût computationnel des modèles d'optimisation [3].

Les futures recherches devraient se concentrer sur le développement de systèmes plus robustes combinant intelligence artificielle, edge computing et cloud computing pour améliorer la prise de décision en mobilité électrique. L'intégration des processus embarqués et débarqués est essentielle pour une gestion efficace de la mobilité électrique. L'utilisation d'algorithmes avancés, combinée aux architectures distribuées et aux systèmes d'apprentissage, permet d'améliorer significativement l'efficacité énergétique et l'optimisation des infrastructures de recharge.

2.3 Lacunes des méthodes existantes

2.3.1 Modélisation énergétique du véhicule

Bien que plusieurs modèles aient été développés pour prédire la consommation énergétique des VE en fonction des conditions de conduite et environnementales [12], ils restent fortement dépendants de données statiques. L'absence de prise en compte dynamique des variations de consommation dues aux conditions météorologiques et au trafic diminue leur précision. De plus, les modèles basés sur des heuristiques manquent de généralisation face aux nouvelles conditions de conduite [9].

2.3.2 Apprentissage automatique et intelligence artificielle

L'usage de l'apprentissage automatique pour la planification et la prédition des besoins en recharge est une avancée majeure [16]. Toutefois, ces modèles nécessitent d'importantes quantités de données annotées, ce qui représente un frein à leur adoption à grande échelle. De plus, les modèles de réseaux neuronaux profonds manquent souvent d'interprétabilité, rendant difficile l'explication des décisions prises par l'algorithme [3]. Enfin, la réactivité des systèmes de recommandation en temps réel est limitée par la latence et la disponibilité des données [17].

2.3.3 Optimisation du routage des véhicules électriques

L'optimisation du routage des VE est un problème complexe combinant des contraintes énergétiques et logistiques. Bien que les modèles multi-objectifs améliorent la gestion des itinéraires, ils restent coûteux en temps de calcul [15]. Les métahéuristiques comme l'algorithme génétique ou la recherche tabou nécessitent de longs temps de convergence pour fournir des solutions optimales, ce qui limite leur applicabilité en temps réel [11]. Par ailleurs, l'absence de données précises sur l'occupation des bornes de recharge peut entraîner des décisions sous-optimales [14].

2.3.4 Prise en compte des facteurs environnementaux

Les modèles existants intègrent rarement l'ensemble des facteurs environnementaux influençant l'autonomie des VE. Par exemple, les effets des vents latéraux et des conditions météorologiques extrêmes restent peu étudiés [2]. De plus, les stratégies de recharge sont souvent basées sur des prévisions statiques sans mise à jour en temps réel [10].

2.3.5 Interaction Véhicule-Infrastructure-Usagers (V2X)

Bien que la communication V2X améliore la gestion des VE, son implémentation reste limitée par l'infrastructure existante. Le déploiement de réseaux de communication adaptés nécessite des investissements massifs et une interopérabilité entre différents acteurs [5]. De plus, la sécurité des échanges d'informations entre véhicules et infrastructures est un défi majeur [17].

2.3.6 Synchronisation des processus embarqués et débarqués

L'un des défis majeurs est la synchronisation entre les décisions locales du véhicule et les stratégies globales du réseau de transport. Les architectures actuelles de fog computing et cloud computing offrent des solutions intéressantes [13], mais souffrent de limitations en matière de scalabilité et de latence [3]. L'optimisation conjointe de la gestion énergétique et du routage reste un problème ouvert.

2.3.7 Défis techniques et scientifiques

Les limites identifiées dans les travaux existants soulignent plusieurs défis clés :

- **Complexité computationnelle** : Les modèles avancés nécessitent une puissance de calcul importante, rendant leur exécution en temps réel difficile [15].
- **Interprétabilité des modèles** : L'explicabilité des décisions prises par les modèles d'intelligence artificielle est un enjeu critique pour leur adoption [16].
- **Fiabilité des données** : L'accès à des données précises et en temps réel est essentiel pour améliorer la précision des prévisions et des recommandations [2].
- **Interopérabilité des systèmes** : L'intégration des différentes plateformes et technologies V2X nécessite des standards unifiés [5].
- **Sécurité et confidentialité** : Les échanges d'informations entre véhicules et infrastructures doivent être sécurisés pour éviter toute manipulation malveillante [17].

Les recherches existantes ont permis de nombreuses avancées dans la gestion des VE, mais elles rencontrent encore des limites importantes. L'amélioration des modèles de consommation énergétique, l'optimisation en temps réel du routage et l'intégration des facteurs environnementaux restent des défis à relever. De nouvelles approches hybrides combinant intelligence artificielle, calcul distribué et systèmes de communication avancés sont nécessaires pour améliorer la mobilité électrique de demain.

2.4 Synthèse des conclusions de l'état de l'art

Les approches existantes ont permis de développer des modèles avancés pour la consommation énergétique, la planification des itinéraires et la gestion des bornes de recharge [12, 16, 15]. Toutefois, plusieurs limitations subsistent :

- **Dépendance aux données statiques** : La plupart des modèles n'intègrent pas les mises à jour en temps réel des conditions de circulation et des disponibilités des bornes [9].
- **Complexité computationnelle** : Les algorithmes d'optimisation, bien qu'efficaces, restent trop coûteux en temps de calcul pour une application en temps réel [11].
- **Interopérabilité limitée** : La communication entre les véhicules et l'infrastructure est encore peu exploitée [5], ce qui réduit l'efficacité des recommandations.
- **Fiabilité des prévisions** : Les prédictions de recharge sont souvent inexactes en raison de la variabilité des comportements des utilisateurs et des conditions environnementales [2].

Ces limites justifient la nécessité d'une approche innovante combinant l'intelligence artificielle, l'optimisation multi-objectifs et l'intégration des systèmes de communication pour améliorer la mobilité électrique.

2.4.1 Justification de l'approche proposée

Notre approche vise à répondre aux problèmes identifiés à travers les axes suivants :

- **Intégration de l'apprentissage automatique** : Utilisation de modèles de machine learning pour affiner les prévisions de consommation énergétique et optimiser dynamiquement les décisions [16].
- **Optimisation multi-objectifs** : Adoption de méthodes hybrides combinant heuristiques et programmation mathématique pour réduire les coûts énergétiques et les délais de recharge [15].
- **Exploitation du V2X** : Mise en place de protocoles de communication entre véhicules et infrastructures pour améliorer la gestion des ressources et la synchronisation des recharges [5].
- **Cloud et fog computing** : Utilisation d'architectures distribuées pour assurer une prise de décision rapide et une meilleure résilience des systèmes [17].

2.4.2 Hypothèses et objectifs de la recherche

Afin de valider cette approche, nous formulons les hypothèses suivantes :

- Une approche hybride combinant intelligence artificielle et optimisation multi-objectifs améliore la précision des prévisions et l'efficacité du routage.
- L'intégration des systèmes V2X permet une gestion optimisée des bornes de recharge et réduit les congestions.
- L'adoption du fog computing réduit la latence des décisions et améliore l'adaptabilité des modèles aux conditions réelles.

L'objectif de cette recherche est de démontrer l'impact positif de ces innovations sur l'efficacité énergétique et la mobilité des véhicules électriques.

En combinant les avancées en intelligence artificielle, en optimisation et en communication, notre approche vise à dépasser les limitations des solutions existantes. Les prochaines étapes incluront l'expérimentation et l'évaluation de ces solutions sur des scénarios réels afin de valider leur efficacité et leur applicabilité à grande échelle.

2.5 Conclusion

En conclusion, cet état de l'art a exploré en profondeur les enjeux et les approches actuelles de l'optimisation de la mobilité intelligente des véhicules électriques (VE). Il révèle que, malgré les progrès significatifs réalisés dans la modélisation énergétique, la planification des itinéraires et la gestion des bornes de recharge, des limitations importantes persistent. Ces limitations concernent principalement la dépendance aux données statiques, la complexité computationnelle des algorithmes d'optimisation, l'interopérabilité limitée entre les véhicules et l'infrastructure, et la difficulté à prédire avec précision les comportements des utilisateurs et les conditions environnementales. Pour surmonter ces défis, une approche innovante est nécessaire, intégrant l'apprentissage automatique pour une prédition dynamique de la consommation et des besoins en recharge, une optimisation multi-objectifs pour minimiser les coûts énergétiques et les délais de recharge, l'exploitation des systèmes V2X pour une gestion collaborative des ressources, et l'utilisation d'architectures distribuées (cloud et fog computing) pour assurer une prise de décision rapide et une meilleure résilience du système. L'avenir de la mobilité électrique durable et optimisée repose sur l'harmonisation de ces différentes approches, permettant ainsi de guider les décisions en matière de parcours et de recharge de manière plus efficace, robuste et adaptative aux conditions réelles et aux préférences des utilisateurs. Les prochaines étapes devront se concentrer sur l'expérimentation et l'évaluation de ces solutions innovantes sur des scénarios réels, afin de valider leur efficacité et leur applicabilité à grande échelle.

Chapter 3

Implémentation et résultats

3.1 Implémentation d'un prototype de navigation urbaine

3.1.1 Objectifs

Dans un premier temps, nous avons cherché à développer un système de planification pour un unique véhicule électrique. Nous simulerons systématiquement un trajet entre la tour Eiffel et le Musée du Louvre.

3.1.2 Méthodologie

Pour implémenter ce premier prototype, nous utilisons trois bibliothèques principales :

- **OSMnx** : utilisé pour télécharger le réseau routier sous forme de graphes à l'aide des données OpenStreetMap.
- **NetworkX** : qui nous permet d'exploiter les graphes que nous avons récupéré et qui nous permettre de réaliser les calculs de plus courts chemins que nous verrons par la suite.
- **Folium** : qui nous servira à afficher notre carte et à visualiser nos calculs.

Notre implémentation suivra les étapes suivantes :

1. Dans un premier temps, de façon très naïve, nous utiliserons récupérerons les coordonnées de départ et d'arrivé. Puis, à l'aide de l'algorithme de Djikstra, nous calculons le plus court chemin (en distance) entre les deux points. Il ne faut pas oublier que le réseau routier est un graphe.
2. Par la suite, nous ne cherchons plus à optimiser la distance, mais à optimiser le temps de trajet. Ainsi, nous pondérons les arrêtes du graph par la vitesse limite de circulation sur le chemin associé. Et, nous recalculons le plus court chemin de la même manière.
3. Puis, nous cherchons à ajouter des contraintes. Par exemple, faire varier le trajet en fonction des conditions météorologiques. Ainsi, grâce à l'API **OpenWeather**, nous récupérons les conditions météorologiques que nous utilisons à nouveau pour pondérer les arrêtes du graphe. Par exemple, en cas de pluie, nous considérons que le trajet est rallongé de 20%.
4. A présent, nous n'oublions pas que notre objectif principal reste les véhicules électriques. C'est pourquoi, nous créons la classe véhicule, qui comportera par exemple une batterie et donc une autonomie. Cela impactera nos trajets.
5. Dans le cas où l'autonomie du véhicule n'est pas suffisante par exemple, il faudra dérouter pour obtenir un trajet qui nous fasse passer par une borne de recharge.

3.1.3 Résultats

Les résultats de notre première implémentation sont les suivants :

Implémentation naïve

Nos résultats se présentent sous la forme suivante :

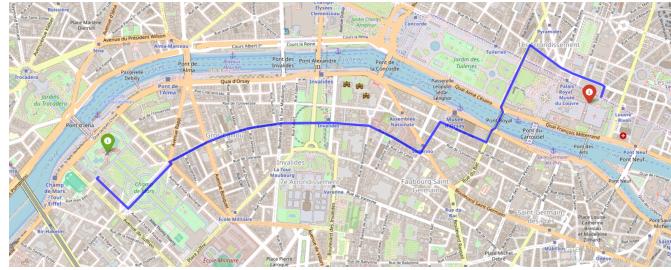


Figure 3.1: Implémentation naïve

Sur cette figure, nous pouvons voir le trajet naïf, calculé par l'algorithme de Djikstra, dans le but de minimiser la distance entre le Musée du Louvre et la tour Eiffel. Le trajet mesure 4.4km.

Implémentation minimisant le temps de trajet en fonction des conditions météorologiques

Par la suite, lorsque nous avons récupérer les limitations de vitesse sur les trajets pour pondérer notre graphe, nous avons pu déterminer le trajet minimisant le temps de trajet et non plus la longueur du trajet.

De plus, nous avons également récupéré les conditions météorologiques, pour ajouter à la pondération de nos arrêtes de graphe.

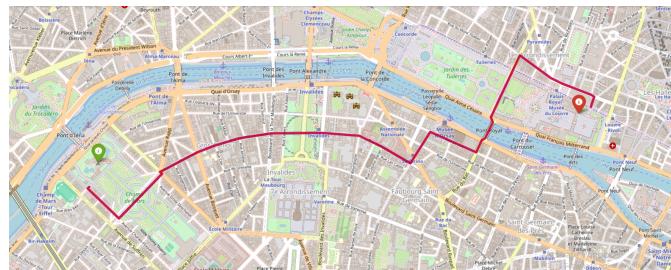


Figure 3.2: Implémentation minimisant le temps de trajet en fonction des conditions météorologiques

Nous observons à présent que le trajet est le même, ce qui fait sens. Sur un trajet aussi court que le notre, les conditions météorologiques sont sensiblement les mêmes. De plus, le trajet le plus court en distance, est également le plus souvent le plus court en temps de trajet.

Pour observer un changement de direction, nous verrons sur la prochaine figure un cas où la batterie de notre véhicule ne nous permet pas d'effectuer le trajet d'une seule traite.

Implémentation avec des contraintes de batterie

Finalement, nous implémentons le concept de véhicule électrique, ayant besoin de se recharger.



Figure 3.3: Trajet avec une batterie suffisante



Figure 3.4: Trajet avec une batterie insuffisante

Dans ce dernier exemple, nous pouvons voir un déroutement, faute de batterie. A gauche, le trajet que nous connaissons bien, de 4.4km. A droite un trajet certes plus long, de 5.8km, mais faisant un escale à 4.0km à une borne de recharge. Ce premier exemple de déroutement, ouvrira la porte à notre deuxième implémentation, qui cherchera à optimiser la borne de recharge choisie pour minimiser la distance, le temps et la consommation.

3.2 Implémentation d'un algorithme d'optimisation.

3.2.1 Principe de l'algorithme

A présent, nous allons chercher à optimiser les trajets, en choisissant avec parcimonie nos bornes. Pour cela, nous utiliserons l'algorithme *Adaptive Large Neighborhood Search* (ALNS). Il s'agit d'une météuristiche particulièrement adaptée aux problèmes multi-objectifs comme le nôtre. En effet, nous cherchons à combiner réduction du coût, de la distance et du prix sous contraintes de l'autonomie du véhicule.

Implémentation des variables de décision

Pour implémenter l'Algorithme, nous commençons par créer des variables de décision.

- . $x_{i,j}$ Est une variable de décision qui vaut 1 dans le cas où l'arc (i, j) est emprunté, 0 sinon.
- . y_i Représente l'état de la batterie lors l'arrivée au sommet j
- . π_i Est l'heure d'arrivée du véhicule au somme i .
- . z_i Est la quantité d'énergie que l'on rechargera à la borne i .
- . P_i Modélise le prix de l'électricité (en KWh) à la borne i .
- . $C_{i,j}$ Représente le coût énergétique du trajet entre i et j .
- . $T_{i,j}$ Est le temps de trajet entre i et j .
- . $d_{i,j}$ Est la distance entre les sommets i et j .
- . $v_{i,j}$ Est la vitesse du véhicule sur l'arc (i, j) (que l'on détermine par la limitation de vitesse).
- . $\tau_{i,j} = \frac{d_{i,j}}{v_{i,j}}$ Est le temps de trajet estimé.
- . $x_{i,j,k,d}$ Est la variable binaire pour structurer les trajets i, j de la voiture k .

Implémentation des classes

Nous implémentons par la suite les différentes classes, ce qui nous permettra par la suite d'implémenter les contraintes.

Ainsi, nous avons :

- La classe Véhicule.
 - . B_{max} La capacité maximale de la batterie.
 - . C_{km} qui est la consommation d'énergie par kilomètre.
 - . V_{eff} est la vitesse effective.
 - . $B_{actuelle}$ est le niveau actuel de la batterie.
 - . V_{max} est la vitesse maximale atteinte par le véhicule.
 - . $P_{utilisateur}$ sera la stratégie adoptée par l'utilisateur. Nous expliciterons cette variable par la suite.
- La classe borne.
 - . $R_{energie}$ Est l'énergie disponible sur le moment à la station de recharge.
 - . $R_{vitesse}$ est la vitesse de recharge en kW/min .

- . R_{type} est le type de borne, elle peut être normale, accélérée, rapide ou ultra rapide.
- . $R_{connecteur}$ est le nombre de connecteurs disponibles sur la borne
- . R_{dispo} Est la disponibilité de la borne, 1 si elle est libre, 0 sinon.
- . R_{prix} est le prix de l'électricité de la borne en kWh .

Ainsi, par exemple, pour une **Renault Zoé** les contraintes seraient les suivantes :

- . $B_{max} > 0 (= 52kWh)$
- . $0 < B_{actuelle} = y_i > B_{max}$
- . $C_{km} > 0 (= 17.2 kWh/100 km)$
- . $0 < V_{eff} = V_{i,j} < V_{max}, V_{max} > 0 = 135km/h$
- . $T_{i,j} > 0$
- . $T_{charge} = \frac{B_{max} - B_{actuelle}}{R_{vitesse}} > 0$
- . $0 < R_{energie} (= 500kWh)$
- . $R_{connecteur} > 0$
- . $0 < R_{vitesse} (= 2.5kW/min)$
- . $R_{dispo} \in \{0, 1\}$
- . $0 < R_{prix} = P_i$

Implementation des fonctions objectifs

A présent, nous avons toutes les contraintes et tous les paramètres pour pouvoir implémenter l'algorithme ALNS. Nous cherchons alors à minimiser trois fonctions objectifs :

- Le coût financier de recharge : $\sum_{h \in \mathcal{H}} \sum_{d \in \mathcal{VE}} \sum_{(i,j) \in \mathcal{B}'} P_h \cdot z_h \cdot C_{d,(i,j)}$
- Le temps de trajet : $\sum_{h \in \mathcal{H}} \sum_{d \in \mathcal{VE}} \sum_{(i,j) \in \mathcal{B}'} \frac{V_{d,(i,j)} \cdot z_h}{R_h}$
- La consommation énergétique de la voiture : $\sum_{d \in \mathcal{VE}} \sum_{(i,j) \in \mathcal{B}'} C_{d,(i,j)} \cdot x_{i,j,d}$

Où :

- \mathcal{H} est l'ensemble des bornes de recharges
- \mathcal{VE} est l'ensemble des véhicules électriques
- \mathcal{B}' est l'ensemble des arcs (i, j) empruntés.

Implémentation des préférences utilisateurs

Comme annoncé précédemment, les utilisateurs auront le choix entre quatre profils distincts. Cela reviendra en réalité à pondérer le poids des variables de décisions. En particulier à optimiser en priorité : Le temps, le coût ou le prix.

Par exemple :

- . Le profil **Urgent** va chercher à minimiser le temps de trajet, quitte obtenir un prix élevé. La pondération sera alors de $0.6 \cdot temps + 0.2 \cdot prix + 0.2 \cdot distance$. Où, ce que nous notons *prix*, *temps* et *distance* sont en réalité les sommes respectives :

$$\begin{aligned}
& - \sum_{h \in \mathcal{H}} \sum_{d \in \mathcal{VE}} \sum_{(i,j) \in \mathcal{B}'} P_h \cdot z_h \cdot C_{d,(i,j)} \\
& - \sum_{h \in \mathcal{H}} \sum_{d \in \mathcal{VE}} \sum_{(i,j) \in \mathcal{B}'} \frac{V_{d,(i,j)} \cdot z_h}{R_h} \\
& - \sum_{(i,j) \in \mathcal{B}'} T_{i,j}
\end{aligned}$$

- . Le profil **Économique** est dédié à minimiser le prix du trajet et va donc pondérer les variables ainsi : $0.2 \cdot temps + 0.6 \cdot prix + 0.2 \cdot distance$.
- . Le profil **écologique**, quant à lui, va minimiser la distance de trajet, et va donc pondérer les variables ainsi : $0.2 \cdot temps + 0.2 \cdot prix + 0.6 \cdot distance$.
- . Enfin, le profil **équilibré** va lui donner un poids équitable à chacune des variables afin de ne pas orienter la décision en quelque sens : $\frac{1}{3} \cdot prix + \frac{1}{3} \cdot temps + \frac{1}{3} \cdot distance$

3.2.2 Méthodologie

Tout comme dans le premier algorithme présenté, nous récupérons le réseau routier ainsi que les coordonnées de la même manière. Cependant, cette fois ci, nous travaillons non plus sur un seul véhicule, mais sur une cinquantaine. De plus, le trajet ne sera plus simplement entre le Musée du Louvre et la Tour Eiffel. Mais de Paris à la résidence de l'un d'entre nous. Enfin, nous générerons une cinquantaine de bornes proposant différentes offres à différents prix et notre objectif sera de choisir parmi celles ci, quel trajet optimise nos objectifs.

3.2.3 Implémentation

Voilà par exemple la description de nos deux premiers véhicules :

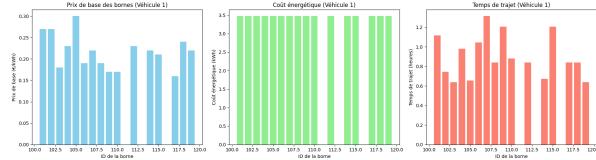


Figure 3.5: Statistiques du premier véhicule

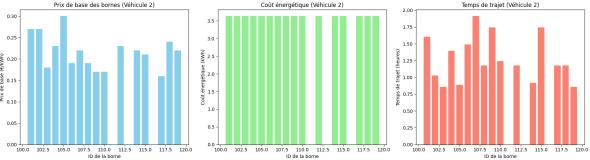


Figure 3.6: Statistiques du deuxième véhicule

Ainsi, nous pouvons voir que différentes bornes ont différents prix et différentes distances par rapport aux véhicules. C'est pourquoi, déterminer le trajet optimal, pour recharger à coût minime se rapporte à un sous problème du problème du voyageur de commerce.

3.2.4 Résultats (Exemple sur le véhicule 1)

Table 3.1: Synthèse des résultats pour le véhicule 1

Heure de départ	06:56
Itinéraire (IDs des nœuds)	[0, 102, 103, 100, 1]
Coût énergétique	3,47 kWh
Coût de recharge	9,93 €
Temps total de trajet	00:38
Coût total (non pondéré)	14,04
Coût objectif pondéré	1,368
Heures d'arrivée	06:56, 07:03, 07:07, 07:33, 07:35
Niveaux de batterie (kWh)	2,89 → 1,33 → 0,16 → 57,99 → 57,57

Table 3.2: Détails de l'arrêt de recharge à la station 103

Heure d'arrivée	07:09
Connecteurs libres	2
Recharge (min)	24,2
Attente (min)	0,0
Temps total à la borne (min)	24,2
Prix dynamique	0,17 €/kWh

A présent, nous voyons les résultats des 50 itérations de l'algorithme ALNS pour le premier véhicule. Nous pouvons y voir :

- Les différents arrêts, qui correspondent aux itérations
- Le prix ainsi que le temps de trajet
- Le coût total / coût total pondéré sont une somme (pondérée) entre le temps, le prix et l'énergie.
- Pour chacune des stations, nous avons l'heure d'arrivée estimé, ainsi que le niveau de batterie correspondant.

Le deuxième tableau est un exemple des informations renvoyées par la station de recharge 103. Nous disposons de ces informations pour chacune des bornes sur le chemin. Nous pouvons y voir :

- L'heure d'arrivée et le temps de recharge
- Le nombre de bornes de recharges
- L'attente éventuelle, ce qui sera notre prochain axe de développement.
- Le prix au kWh

3.3 Implémentation d'un algorithme de négociation

3.3.1 Principe et méthode

La dernière étape de notre projet consiste à, au delà de trouver une borne optimale, voir s'il est possible de négocier avec d'autres afin d'obtenir une borne pour un prix encore meilleur.

Pour cela, nous générerons à nouveau une cinquantaine de véhicules, mais nous faisons également varier le prix des bornes.

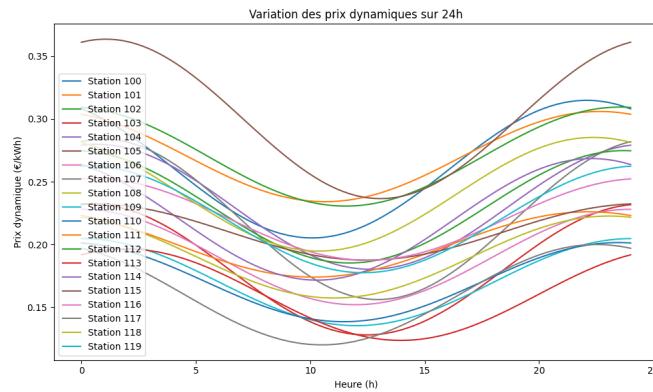


Figure 3.7: Prix des différentes bornes en fonction de l'heure de la journée

A présent, nous sommes en concurrence avec d'autres véhicules, ainsi, dans le cas où la borne choisie par l'algorithme ALNS n'est pas disponible, nous pouvons engager une négociation.

Pour implémenter notre négociation, nous nous baserons sur ces principes fondamentaux :

- La borne optimale déterminée par l'algorithme ALNS n'est pas disponible (occupée par exemple)
- La borne ne descendra pas en dessous de 75% de son prix initial
- La prix doit être avantageux pour l'utilisateur, autrement, il ira tout de même à la borne ALNS et attendra qu'elle se libère.

3.3.2 Quelques exemples de négociation

Une négociation aboutie

Si tout ce passe bien, une négociation se passe de la façon suivante :

Table 3.3: Une négociation aboutie

Paramètre	Valeur
Heure de départ	00:44
Borne choisie par ALNS	ID 104 (0,18 €/kWh)
Borne la plus rapide	ID 119 (0,19 €/kWh)
Décision de négociation	Acceptée
Nouveau prix de la borne rapide	0,18 €/kWh
Itinéraire (IDs)	[0, 119, 1]
Coût énergétique	3,80 kWh
Coût de recharge	14,70 €
Temps de trajet	00:41
Coût total (brut)	19,18
Coût objectif (pondéré)	5,19
Heures d'arrivée	[00:44, 00:45, 01:25]
Niveaux de batterie (kWh)	[2,62, 2,39, 64,87]

Nous pouvons voir qu'ici, le véhicule réussit à faire baisser le prix de la borne de 0.01€/kWh et il est donc maintenant plus optimal de passer par cette nouvelle borne, due au fait que le temps d'attente est plus court, sans que le prix ne soit plus élevé.

Une négociation échouée

Cependant, il arrive que le détour pour une borne soit trop conséquent ou que l'écart de prix entre les bornes soit trop important, dans ces cas là, la négociation échoue. Dans ce cas, on peut voir que le détour et l'écart de prix font

Table 3.4: Négociation rejetée)

Paramètre	Valeur
Heure de départ	00:22
Borne choisie par ALNS	ID 110 (0,15 €/kWh)
Borne la plus rapide	ID 114 (0,22 €/kWh)
Temps de trajet proposé	00:57
Décision de négociation	Rejetée
Raison	Discount demandé (31,8%) dépasse la limite de 25%
Itinéraire (IDs)	[0, 110, 116, 1]
Coût énergétique	4,57 kWh
Coût de recharge	17,98 €
Temps de trajet	00:60
Coût total (brut)	23,54
Coût objectif (pondéré)	1,87
Heures d'arrivée	[00:22, 00:27, 01:10, 01:22]
Niveaux de batterie (kWh)	[1,10, 0,01, 96,38, 93,56]

que le véhicule demande à la station de recharge une réduction de 31.8%, ce qui est au dessus de ce que la borne est prête à accorder (25%). La négociation échoue donc et l'itinéraire nous fait donc passer par la borne ALNS, quitte à attendre.

3.4 Résultat final

Après avoir effectué différentes négociations, nous pouvons router une multitude de véhicules afin de ne pas avoir d'attente lors des recharges.



Figure 3.8: Itinéraire final

Nous pouvons voir que les différents véhicules commencent par se séparer en partant de Paris avant de tous rejoindre l'axe principal pour finir à destination.

Ce résultat est prometteur et nous pouvons espérer, à grande échelle et dans un futur proche, fluidifier le trafic routier en évitant de congestionner les axes principaux en particulier à proximité de stations de recharge.

Chapter 4

Conclusion

4.1 Synthèse du projet

Ce projet de fin d'études s'inscrit dans le cadre des enjeux contemporains liés à la mobilité durable et intelligente. Face à l'apparition et au développement des véhicules électriques ainsi qu'aux contraintes croissantes en matière de gestion énergétique, il nous a paru intéressant de développer des solutions de planification optimisées prenant en compte à la fois les besoins des usagers, les conditions environnementales et les capacités du réseau.

Notre travail a d'abord été d'explorer en l'état de l'art sur les approches d'optimisation multi-objectifs, l'intelligence artificielle, les modèles énergétiques et les systèmes de communication véhicule-infrastructure (V2X). Ce qui nous a permis d'avoir des idées d'implémentation.

Sur la base de ces constats, et sous les conseils de notre tuteur côté entreprise M. **Samir Aknine** nous avons développé un prototype d'optimisation basé sur l'algorithme *ALNS* (*Adaptive Large Neighborhood Search*), couplé à un modèle prenant en compte les stratégies utilisateur (minimisation du coût, du temps, ou équilibre des deux). Ce prototype permet de simuler dynamiquement les choix de parcours et de recharge dans un environnement urbain, en intégrant des données telles que la tarification dynamique ou l'état des stations.

Les résultats obtenus, bien que perfectibles, sont prometteurs. Ils montrent une amélioration notable des performances par rapport à des stratégies statiques ou naïves, en particulier en termes de réduction du coût énergétique et de fluidification du trafic. De plus, l'approche personnalisable du modèle selon les préférences utilisateur pourrait s'avérer utile en cas de déploiement à grande échelle.

4.2 Limites du prototype développé

Malgré les résultats obtenus, certaines limites ont été identifiées :

- La taille et la diversité des cas de test simulés restent encore modestes
- Le modèle ne prend pas encore en compte l'évolution dynamique de certains paramètres (trafic, météo, pannes)
- Le temps de calcul de l'algorithme ALNS, bien que acceptable, reste sensible à l'échelle du réseau. Nos tests mettaient quelques heures à s'exécuter.
- L'approche reste centralisée : la dimension multi-agent mériterait d'être développée davantage.

4.3 Perspectives d'amélioration

Plusieurs perspectives peuvent être envisagées pour améliorer ce travail :

- **Raffinement du modèle de décision** : prise en compte d'éléments contextuels comme la météo, les incidents, ou les événements locaux

- **Optimisation temps réel** : intégration d'approches hybrides (métaheuristiques + apprentissage automatique) pour améliorer la réactivité
- **Dimension multi-agent** : gestion d'une flotte de VE en interaction, avec simulation de comportements coopératifs ou concurrents
- **Interfaçage avec un simulateur** : connecter le modèle à un simulateur de trafic ou de mobilité (SUMO, Vissim, etc.) pour une évaluation plus fine.

Conclusion générale

Ce travail a confirmé la pertinence des modèles d'optimisation multi-objectifs pour guider les décisions de mobilité des VE dans des contextes urbains complexes. Il constitue une première brique vers la construction de systèmes de navigation et de recharge intelligents, adaptatifs et durables.

Bibliography

- [1] Andreas Artmeier, Julian Haselmayr, Martin Leucker, and Michael Sachenbacher. The shortest path problem revisited: Optimal routing for electric vehicles. *KI 2010: Advances in Artificial Intelligence*, pages 309–316, 2010.
- [2] Lucile Buisson. *Propositions méthodologiques pour l'évaluation de l'introduction du véhicule autonome au niveau local*. Thèse de doctorat, Université de Lyon, 2022.
- [3] Djabir Abdeldjalil Chekired, Dhaou Said, Lyes Khoukhi, and Hussein T. Mouftah. Dynamic pricing model for ev charging-discharging service based on cloud computing scheduling. In *International Wireless Communications and Mobile Computing Conference (IWCMC)*, pages 798–807, 2017.
- [4] Djabir Abdeldjalil Chekired, Dhaou Said, Lyes Khoukhi, and Hussein T. Mouftah. Dynamic pricing model for ev charging-discharging service based on cloud computing scheduling. In *International Wireless Communications and Mobile Computing Conference (IWCMC)*, pages 798–807, 2017.
- [5] Djabir Abdeldjalil Chekired, Mohammed Amine Togou, and Lyes Khoukhi. Hierarchical wireless vehicular fog architecture: A case study of scheduling electric vehicle energy demands. *IEEE Vehicular Technology Magazine*, 13(4):36–45, 2018.
- [6] AAMAS Conference. Multi-agent systems for intelligent vehicle routing. In *Proceedings of the International Conference on Autonomous Agents and Multi-Agent Systems*, 2023.
- [7] ECAI Conference. Multi-objective optimization in electric vehicle route planning. In *Proceedings of the European Conference on Artificial Intelligence*, 2023.
- [8] IJCAI Conference. Artificial intelligence and route optimization for electric vehicles. In *Proceedings of the International Joint Conference on Artificial Intelligence*, 2023.
- [9] Marek Cuchy and al. Modélisation multi-objectif pour la gestion de l'autonomie des véhicules électriques. *Journal de la Mobilité Intelligente*, 12(1):45–67, 2024.
- [10] des transports et des mobilités DGITM Direction générale des infrastructures. Acceptabilité de la mobilité routière automatisée et connectée: Revue bibliographique des travaux 2023. Technical report, Ministère de la Transition Écologique, France, 2023.
- [11] Mustafa Keskin and Hande Yaman. An exact method for the electric vehicle routing problem with time windows and partial recharges. *Transportation Science*, 53(2):496–521, 2019.
- [12] Oulad Kouider. *Optimisation et Planification des tournées de véhicules électriques*. Thèse de doctorat, Université Paris-Saclay, 2020.
- [13] Tayeb Oulad Kouider. *Optimisation de la planification des tournées de véhicules électriques*. Thèse de doctorat, Université de Lorraine, 2020.
- [14] Gizem Ozbaygin, Oya Karasan, Martin Savelsbergh, and Hande Yaman. A branch-and-price algorithm for the vehicle routing problem with roaming delivery locations. *Operations Research*, 71(3):765–789, 2023.
- [15] Kousik Rajesh, Eklavya Jain, and Prakash Kotchappa. A multi-objective approach to the electric vehicle routing problem. *International Journal of Transport Science and Technology*, 9(2):145–167, 2022.

- [16] Sakib Shahriar, A. R. Al-Ali, Ahmed H. Osman, Salam Dhou, and Mais Nijim. Prediction of ev charging behavior using machine learning. *IEEE Transactions on Transportation Electrification*, 7(3):1234–1246, 2021.
- [17] Mohammed Amine Togou, Djabir Abdeldjalil Chekired, and Lyes Khoukhi. A hierarchical software-defined networking-based architecture for fog-enabled vehicular networks. *IEEE Internet of Things Journal*, 5(6):5222–5232, 2018.